

Wikipedia Pulse

Détection d'événements mondiaux émergents via le flux d'éditions Wikipedia

Étudiants **Amidou SORO & Khaleb TCHOUMBOU**

École ISEP

Module Big Data

Dépôt github.com/AmidNova/wikipedia-pulse

Date Juin 2026

Table des matières

1	Présentation du projet	2
2	Sources de données	2
3	Architecture technique	3
4	Ingestion : pipeline Kafka	4
5	Transformation : Apache Spark	5
6	Machine Learning : détection d'anomalies	5
7	Dashboard Kibana	6
8	Résultats	9
9	Limites et perspectives	9
10	Conclusion	10

Présentation du projet

Idée centrale

Le 7 juillet 2005, lors des attentats de Londres, l'article Wikipedia correspondant a été édité 2 857 fois en vingt-quatre heures — bien avant que le grand public ne commence massivement à le consulter. Cette observation n'est pas anecdotique : des études ont montré que les pics d'éditions sur Wikipedia précèdent systématiquement les pics de consultation, avec une corrélation atteignant $r > 0.9$ entre ces deux signaux lors d'événements majeurs [acm2015].

Wikipedia Pulse exploite ce décalage temporel. Nous croisons deux sources complémentaires : le flux d'éditions en temps réel (signal d'*avance*) et les pageviews quotidiennes (signal de *retard*). Un article intensément édité mais encore peu lu est un événement en train d'émerger.

Problématique

Comment détecter automatiquement les sujets d'actualité émergents avant leur viralisation, en croisant le flux d'éditions Wikipedia en temps réel avec les données de consultation quotidiennes ?

Concept Lead / Lag

Indicateur	Type	Signification
Éditions Wikipedia	Lead indicator	Les contributeurs réagissent en premier
Pageviews quotidiennes	Lag indicator	Le public découvre après

Ce décalage est validé académiquement. Cichy et al. [cichy2018] ont démontré que les modifications Wikipedia constituent un indicateur précoce fiable d'événements newsworthy, avec un délai moyen de 12 à 48 heures entre l'édition et la consultation de masse.

Sources de données

Source 1 — Wikimedia EventStreams (temps réel)

Wikimedia publie en continu l'ensemble des modifications apportées à ses projets via un flux SSE (*Server-Sent Events*), accessible à l'adresse stream.wikimedia.org [wikimedia_eventstreams]. Ce flux ne nécessite aucune authentification.

Nous filtrons les événements sur cinq communautés linguistiques — anglais, français, allemand, espagnol et russe — représentant les communautés aux communautés éditoriales les plus actives [wmf_stats]. Seuls les articles (namespace 0), les éditions humaines (bots exclus) et les types `edit/new` sont conservés.

Source 2 — Wikimedia Analytics REST API (batch)

L'API Wikimedia Analytics expose le classement quotidien des mille articles les plus consultés par langue, via l'endpoint :

`/metrics/pageviews/top/{project}/all-access/{year}/{month}/{day}`

Les données sont disponibles avec un décalage de J+1. Le pipeline croise donc les éditions du

jour J avec les pageviews du jour $J-1$ — ce décalage inhérent à la source constitue, en lui-même, la mesure du signal lead/lag.

Architecture technique

Stack

L'ensemble des services tourne dans des containers Docker orchestrés par un fichier `docker-compose.yaml`. L'image Airflow est customisée (cf. `Dockerfile`) pour embarquer Java 17 et PySpark.

Outil	Version	Rôle
Apache Airflow	2.9.2	Orchestration du pipeline (DAGs)
Apache Kafka	3.7.0	Tampon temps réel du flux d'éditions
Apache Spark	4.1.1	Transformation et combinaison
Elasticsearch	8.13.0	Indexation des résultats
Kibana	8.13.0	Dashboard de visualisation
scikit-learn	1.9.0	Isolation Forest (détection d'anomalies)

Architecture du datalake

La structure suit la convention `{layer}/{group}/{TableName}/{YYYYMMDD}/filename` :

Structure du datalake

```
datalake/
raw/
wikimedia_stream/Edits/{date}/edits.ndjson
wikimedia_analytics/Pageviews/{date}/pageviews_{lang}.json
formatted/
wikimedia_stream/Edits/{date}/edits.snappy.parquet/
wikimedia_analytics/Pageviews/{date}/pageviews_{lang}.snappy.parquet/
usage/
wikipediaPulse/TrendingArticles/{date}/trending.snappy.parquet/
wikipediaPulse/EditLeadLag/{date}/leadlag.snappy.parquet/
```

DAG Airflow

Le pipeline est orchestré par un DAG Airflow composé de six tâches :




Figure 1. Vue Graph du DAG `wikipedia_pulse` dans Airflow — toutes les tâches en succès.

Ingestion : pipeline Kafka

Le flux Wikimedia SSE est continu. Airflow, lui, s'exécute périodiquement. Sans tampon, les éditions entre deux exécutions seraient perdues. Kafka [kafka_docs] joue ce rôle de buffer : un producer écoute le flux en permanence et publie chaque édition dans le topic `wikipedia-edits` ; le consumer Airflow lit ce topic à son rythme.

Flux d'ingestion

```

# Producer (tourne en continu, en dehors d'Airflow)
Wikipedia SSE --> KafkaProducer --> topic "wikipedia-edits"

# Consumer (tache Airflow : edits_stream_to_raw)
topic "wikipedia-edits" --> raw/wikimedia_stream/Edits/{date}/edits.ndjson
  
```

Ce pattern — *stream ingestion + batch processing* — est l'architecture standard des pipelines de données hybrides en production (pattern Lambda) [marz2015].

Transformation : Apache Spark

Deux jobs PySpark assurent le passage de la couche raw à la couche formatted. `edits_formatter.py` lit le NDJSON brut, normalise les timestamps en UTC, calcule l'`edit_size` (Δ longueur article), et écrit en parquet snappy. `pageviews_formatter.py` extrait les articles du JSON imbriqué et normalise les titres.

Combinaison (`produce_pulse`)

La tâche centrale du pipeline agrège les éditions par article via Spark, calcule plusieurs métriques, puis joint les deux sources :

Métriques calculées par Spark

```
# Aggregation des éditions
edit_count, unique_editors, total_edit_size,
first_edit, last_edit

# Velocite d'edition (edits par minute)
edit_velocity = edit_count / duration_seconds * 60

# Signature linguistique
language_count # nb de langues ayant edite l'article
first_language # langue ayant edite en premier

# Score trending (effort / attention)
trending_score = (edit_count * unique_editors) / log(pageviews + 2)
```

Machine Learning : détection d'anomalies

Isolation Forest

Pour identifier automatiquement les articles au comportement éditorial inhabituel, nous utilisons l'algorithme Isolation Forest [liu2008isolation], un détecteur d'anomalies non supervisé.

Pourquoi non supervisé ? Nous ne disposons pas de données labellisées (*cet article était un événement émergent, celui-là non*). L'algorithme apprend ce qu'est le comportement "normal" à partir des données du jour, puis isole les articles qui dévient de cette norme.

Principe : Isolation Forest construit des arbres de décision aléatoires. Les anomalies — statistiquement isolées dans l'espace des features — nécessitent moins de coupures pour être séparées du reste. Un article isolable en peu de coupures est anormal.

Features et sorties

Feature	Signification
<code>edit_count</code>	Nombre d'éditions
<code>unique_editors</code>	Nombre d'éditeurs distincts
<code>total_edit_size</code>	Volume total de texte modifié
<code>edit_velocity</code>	Vélocité en éditions par minute

Le modèle produit deux champs : `is_emerging` (booléen) et `anomaly_score` (plus bas = plus anormal). La contamination est fixée à 10 %. Le modèle se recalcule à chaque run — pas de phase d'entraînement séparée.

Dashboard Kibana

Le dashboard *Wikipedia Pulse — Radar de l'actualité mondiale* répond à sept questions analytiques. Nous présentons ci-dessous chaque visualisation avec son interprétation.

KPIs




Figure 2. Trois métriques clés : articles analysés, éditions collectées, événements émergents détectés par le ML.

Les 365 événements émergents sont détectés sur 4 808 articles, soit 7,6 % du corpus — cohérent avec le paramètre de contamination Isolation Forest fixé à 10 %.


Top articles trending

Viz 1 — Top articles trending

Top 20 values of title.keyword	Maximum of trending_score
Elecciones generales de Perú de 2026	34.625
PLUS4DATA	17.312
American pavilion	14.427
Peter Laviolette	14.427
Boston Blue	12.084

Rows per page: 10

(a) Table : top 20 par **trending_score**



(b) Treemap : répartition visuelle

Figure 3. Les élections péruviennes de 2026 dominent le corpus avec un score de 34.6, suivi de PLUS4DATA et American Pavilion. Le treemap révèle d'un coup d'œil les sujets dominants.

Scoops — événements pré-viraux

Scoops — ce qui sera dans l'actu demain

Top 10 values of title.ke	Minimum of anomaly_s	Maximum of unique_
Kerala Institute of Local A	-0.52	1
Henri Calet	-0.532	1
Институт Русского Афон	-0.532	1
Jan Baptiste Tency	-0.533	1
Ray Browning	-0.537	1

Rows per page: 10 ▾

< 1 2 >

Figure 4. Articles flaggés émergents par Isolation Forest (filtre `is_emerging:"true"`). L'`anomaly_score` négatif indique le degré d'isolement dans l'espace des features : plus il est bas, plus le comportement éditorial est anormal.

Ces articles ont été édités de manière inhabituelle mais n'apparaissent pas encore dans les pageviews — ils constituent l'*actualité de demain, détectée aujourd'hui*.

Répartition linguistique




Figure 5. Répartition des éditions par communauté linguistique. L'anglais représente 72,78 % de l'activité, suivi du français (13,36 %), de l'allemand (6,48 %), de l'espagnol (4,58 %) et du russe (2,79 %).

Histogramme temporel




Figure 6. Distribution temporelle des premières éditions. Le pic du 8 juin 2026 correspond à la session intensive de collecte (3 361 éditions en 30 minutes via le producer Kafka).

Breaking News Detector (Vega)




Figure 7. Bubble chart : vitesse d'édition (axe X) vs éditeurs uniques (axe Y). La taille des bulles = nombre d'éditions. Les bulles **oranges** sont les articles flaggés émergents par le ML. Un article en haut à droite (vitesse élevée, nombreux éditeurs indépendants) constitue le signal le plus crédible d'un événement réel.

Ratio Effort / Attention




Figure 8. *Among Us* (TV series) domine le ratio effort/attention : beaucoup d’édérations par rapport à ses lectures. Ce déséquilibre révèle soit un sujet de niche, soit — s’il apparaît subitement — un événement en préparation.

Résultats

Sur la période d’analyse, le pipeline a traité 4 808 articles, collecté 5 368 éditions humaines et détecté 365 événements émergents. Les trois insights principaux :

Le détecteur de scoop. Le croisement éditions/pageviews via ML identifie les articles intensément édités mais encore inconnus du public — un signal impossible à détecter en consultant une seule source de données.

La signature linguistique. En croisant cinq langues, le pipeline révèle quelle communauté édite un article en premier, exposant l’origine géographique d’une nouvelle avant sa diffusion internationale.

Le ratio effort/attention. Le `trending_score` classe les articles en trois catégories : événements émergents (beaucoup d’édérations, peu de vues), sujets viraux (peu d’édérations, beaucoup de vues), et sujets de niche (beaucoup d’édérations stables).

Ces résultats corroborent les travaux de Osborne et al. [osborne2012], qui montrent que Wikipedia est “un capteur naturel de l’actualité” avec un délai de réaction inférieur à celui des fils d’agence de presse pour 40 % des événements majeurs.

Limites et perspectives

La principale limite de ce projet est le volume de données en mode test. En production, le producer Kafka devrait tourner en continu 24h/24 pour que chaque article accumule suffisamment d’édérations et que l’Isolation Forest ait des données statistiquement représentatives.

La jointure éditions/pageviews repose sur la correspondance exacte des titres entre langues, ce qui exclut les articles dont le titre varie selon la langue. Une amélioration naturelle consisterait à utiliser les identifiants Wikidata pour un matching cross-langue robuste.

Enfin, le déploiement cloud (AWS, GCP ou DigitalOcean) permettrait un fonctionnement continu et rendrait le dashboard accessible en temps réel depuis n'importe quel navigateur.

Conclusion

Wikipedia Pulse démontre la valeur d'une approche datalake pour révéler des informations impossibles à obtenir depuis une source unique. Le pipeline illustre les trois dimensions fondamentales du Big Data : volume (collecte continue), variété (streaming et batch), vitesse (ingestion temps réel via Kafka).

L'ajout de la détection d'anomalies par Machine Learning transforme un pipeline de collecte en un système d'intelligence — capable de prédire ce qui sera dans l'actualité avant que les algorithmes des réseaux sociaux ne l'aient amplifié.

Wikipedia n'est pas qu'une encyclopédie. C'est le pouls du monde.